

Contoh Perhitungan Manual Lapisan Keluaran dan Evaluasi IndoBERT

Sentimen Ulasan Pengguna Aplikasi Gojek di Google Play Store Berbasis IndoBERT

Metode penelitian ini adalah fine-tuning IndoBERT. Perhitungan seluruh jaringan tidak dilakukan dengan tangan karena model memiliki sekitar 110 juta parameter. Bagian yang masih dapat dihitung secara manual adalah lapisan keluaran (softmax) dan metrik evaluasi dari confusion matrix.

Angka contoh berasal dari keluaran model hasil fine-tuning. Beberapa nilai logit dibulatkan agar perhitungannya mudah diikuti, sehingga dapat muncul selisih kecil dari keluaran program.

1. Lapisan Keluaran Model

Untuk klasifikasi dua kelas, vektor [CLS] berdimensi 768 dipetakan menjadi dua logit: $z(\text{negatif}) = W_{\text{neg}} \times h + b_{\text{neg}}$ dan $z(\text{positif}) = W_{\text{pos}} \times h + b_{\text{pos}}$. Probabilitas dihitung dengan softmax: $P(c) = e^{z(c)} / (e^{z(\text{negatif})} + e^{z(\text{positif})})$. Kelas dengan probabilitas terbesar menjadi prediksi akhir.

Pada persamaan tersebut, h merupakan representasi teks dari encoder, W adalah bobot lapisan klasifikasi, dan b adalah bias. Logit merupakan skor sebelum softmax, sehingga dapat bernilai negatif maupun positif. Softmax mengubah skor tersebut menjadi probabilitas dengan jumlah 1.

Probabilitas pada tabel berikut dihitung dari logit dua desimal. Karena itu, hasilnya dapat berbeda sedikit dari keluaran program yang menggunakan logit dengan ketelitian penuh. Pembulatan sebaiknya dilakukan pada hasil akhir.

No	Ulasan	z negatif	z positif	P(positif)	Prediksi
U1	Driver ramah banget, pelayanannya cepat dan bagus	-3,44	3,07	0,9985	POSITIF
U2	Aplikasinya sering error dan lemot, driver susah dicari	0,75	-0,77	0,1795	NEGATIF
U3	Driver ramah tapi aplikasinya sering error	-2,95	2,75	0,9967	POSITIF (keliru)

Tabel 1. Logit dan probabilitas positif dari logit yang dibulatkan

Perhitungan manual U1

$e^{-3,44} = 0,0321$; $e^{3,07} = 21,5419$; jumlah = 21,5740. $P(\text{positif}) = 21,5419 / 21,5740 = 0,9985$, sehingga prediksinya POSITIF. $P(\text{negatif}) = 0,0015$.

Pada U1, logit positif jauh lebih besar daripada logit negatif. Probabilitas positif sekitar 99,85% membuat kelas positif dipilih. Namun, probabilitas tinggi tidak menjamin bahwa setiap prediksi model selalu benar.

Perhitungan manual U2

$e^{0,75} = 2,1170$; $e^{-0,77} = 0,4630$; jumlah = 2,5800. $P(\text{negatif}) = 2,1170 / 2,5800 = 0,8205$, sedangkan $P(\text{positif}) = 0,1795$. Karena probabilitas negatif lebih besar, prediksinya NEGATIF. Program menghasilkan $P(\text{negatif})$ sekitar 0,8218; perbedaan ini berasal dari pembulatan logit.

Dengan logit 0,7546 dan -0,7738 yang dicantumkan dalam dokumen awal, diperoleh P(negatif) sekitar 0,8218 dan P(positif) sekitar 0,1782. Perbedaan dengan hasil tabel disebabkan oleh pembulatan logit. Keduanya tetap menghasilkan prediksi negatif.

Perhitungan manual U3

$e^{(-2,95)} = 0,0523$; $e^{(2,75)} = 15,6426$; jumlah = 15,6949. $P(\text{positif}) = 0,9967$ dan $P(\text{negatif}) = 0,0033$, sehingga model memprediksi POSITIF. Label acuan pada contoh ini negatif, jadi contoh ini merupakan salah prediksi pada ulasan dengan opini campuran.

U3 memuat penilaian positif terhadap driver dan keluhan terhadap aplikasi. Pemberian satu label untuk seluruh ulasan menyederhanakan dua penilaian yang berbeda. Pada pengembangan selanjutnya, klasifikasi berdasarkan aspek dapat digunakan untuk membedakan sentimen terhadap driver dan aplikasi.

2. Perhitungan Metrik Evaluasi

Dari 280 data uji, confusion matrix dengan baris sebagai label aktual dan kolom sebagai prediksi adalah sebagai berikut:

	Prediksi negatif	Prediksi positif
Aktual negatif	127 (TN)	13 (FP)
Aktual positif	17 (FN)	123 (TP)

Tabel 2. Confusion matrix pada 280 data uji

Dengan kelas positif sebagai kelas utama: $TP = 123$, $FN = 17$, $FP = 13$, dan $TN = 127$.

TP berarti ulasan positif yang diprediksi positif, sedangkan TN berarti ulasan negatif yang diprediksi negatif. FP adalah ulasan negatif yang diprediksi positif, dan FN adalah ulasan positif yang diprediksi negatif. Jumlah seluruh sel adalah 280, dengan 250 prediksi benar dan 30 prediksi salah.

Akurasi = $(123 + 127) / 280 = 0,8929$ (89,29%).

Precision positif = $123 / (123 + 13) = 0,9044$.

Recall positif = $123 / (123 + 17) = 0,8786$.

F1 positif = $2 \times 0,9044 \times 0,8786 / (0,9044 + 0,8786) = 0,8913$.

Precision negatif = $127 / (127 + 17) = 0,8819$.

Recall negatif = $127 / (127 + 13) = 0,9071$.

F1 negatif = 0,8944.

Akurasi menunjukkan proporsi seluruh prediksi yang benar. Precision positif menunjukkan proporsi prediksi positif yang sesuai dengan label acuan. Recall positif menunjukkan proporsi data berlabel positif yang berhasil dikenali. F1-score merangkum precision dan recall menggunakan rata-rata harmonik.

Untuk kelas negatif, kelas yang dinilai diperlakukan sebagai kelas target. F1 negatif dapat dihitung langsung sebagai $2 \times 127 / (2 \times 127 + 17 + 13) = 0,8944$. Perhitungan dari jumlah data membantu menghindari selisih karena pembulatan precision dan recall.

Precision macro = $(0,9044 + 0,8819) / 2 = 0,8932$. Recall macro = $(0,8786 + 0,9071) / 2 = 0,8929$. F1 macro = $(0,8913 + 0,8944) / 2 = 0,8928$.

Macro average memberikan bobot yang sama kepada kedua kelas dengan merata-ratakan nilai masing-masing kelas. F1 macro merupakan rata-rata F1 per kelas, bukan hasil perhitungan F1 dari precision macro dan recall macro. Nilai akhir dibulatkan menjadi empat angka desimal setelah perhitungan dengan ketelitian penuh.

3. Ringkasan

Lapisan keluaran IndoBERT menggunakan softmax atas dua logit. Dari 280 data uji diperoleh akurasi 89,29%, precision macro 89,32%, recall macro 89,29%, dan F1 macro 89,28%. Contoh U3 menunjukkan keterbatasan model ketika satu ulasan memuat opini positif dan negatif sekaligus.